Analyse en Composantes Principales

Marie-Pierre Etienne

https://marieetienne.github.io/MAF/

2026-11-10

Et on commence avec les manchots

Rappel des données sur les manchots

Données disponibles dans le package `palmerpenguins` mises à disposition par le Dr. Kristen Gorman et the Palmer Station, Antarctica LTER.

On a mesuré les caractéristiques morphologiques de divers manchots :

- bill_length_mm : la longueur du bec,
- bill_depth_mm : l'épaisseur du bec,
- flipper_length_mm : la longueur de la nageoire,
- body_mass_g : le poids du corps.

Les 6 premières lignes (parmi 333)

```
# A tibble: 333 x 4
  bill_length_mm bill_depth_mm flipper_length_mm body_mass_g
           <dbl>         <dbl>             <int>       <int>
1           39.1          18.7               181        3750
2           39.5          17.4               186        3800
3           40.3          18                 195        3250
4           36.7          19.3               193        3450
5           39.3          20.6               190        3650
6           38.9          17.8               181        3625
# i 327 more rows
```

Comment visualiser au mieux ces données pour faire apparaître les liens entre variables et identifier des resemblances entre individus ?

Voir c'est comprendre : comment représenter l'information contenue dans ce tableau ?

Objectifs

- Représenter sans perdre trop d'information,
- Quantifier la perte d'information,
- Comprendre quelles sont les informations redondantes (variables liées),
- Idéalement des individus éloignés dans le nuage initial, restent éloignés dans la représentation

Dans toute la suite, sans perte de généralité, on va considérer que les variables sont centrées.

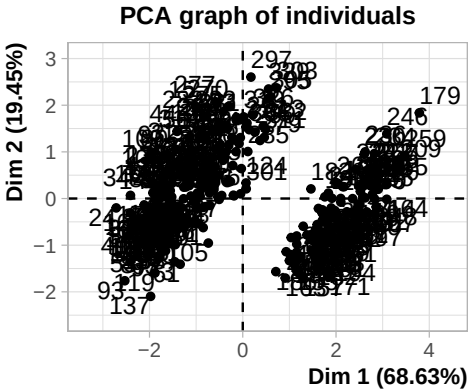
Si on savait faire une Analyse en Composantes Principales


```
library(FactoMineR)
dta <- penguins %>% select(bill_length_mm, bill_depth_mm, flipper_
penguins.PCA <- PCA(X = dta, ncp = 4, graph = FALSE)
```

Si on savait faire une Analyse en Composantes Principales

L'ACP permet de trouver la projection en 2 dimensions qui préserve au mieux l'information contenue dans le nuage de points (avec peu de déformation).

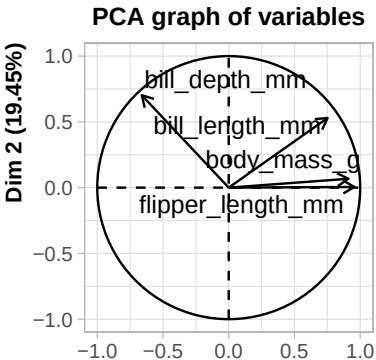
```
plot(penguins.PCA, choix = "ind")
```



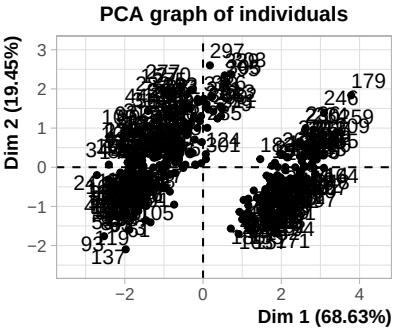
Si on savait faire une Analyse en Composantes Principales

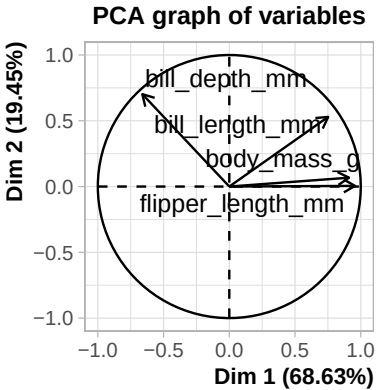
L'ACP définit de nouvelles variables, les composantes principales qui sont une combinaison linéaire des anciennes variables. On peut représenter les variables dans le premier plan de l'ACP.

```
plot(penguins.PCA, choix = "var")
```



Si on savait faire une Analyse en Composantes Principales





Les données

Mise en forme des données

L'ACP s'applique à des données quantitatives sous forme de tableau. Ce tableau est composé de n individus (lignes) et de p variables (colonnes).

Dans la suite on va noter X la matrice des données, $X \in \mathbb{R}^{n \times p}$.

x_{ij} est la valeur de la variable j mesurée pour l'individu i.

$$X = \begin{array}{c} \begin{array}{ccccc} var_1 & \dots & \dots & \dots & var_p \end{array} \\ \begin{pmatrix} x_1^1 & \dots & \dots & \dots & x_1^p \\ \vdots & & & & \vdots \\ & & x_i^j & & \\ \vdots & & & & \vdots \\ x_n^1 & & & & \dots x_n^p \end{pmatrix} \end{array}$$

Deux points de vue complémentaires

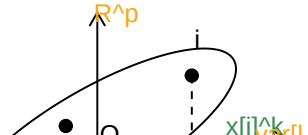
Le nuage des individus C^n

On peut considérer qu'un individu i est un vecteur x_i dans un espace de dimension p. Par convention tous les vecteurs sont des vecteurs colonnes, donc on peut écrire

$$X = \begin{pmatrix} {x_1}^\top \\ \vdots \\ {x_n}^\top \end{pmatrix},$$

L'ensemble des n vecteurs forme le nuage des individus (ce qu'on représente classiquement).

Représentation du nuage des individus



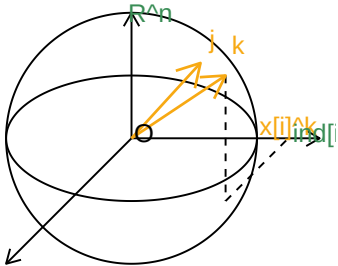
Le nuage des variables C^p

On peut considérer qu'une variable j est un vecteur x^j dans un espace de dimension n et on peut écrire

$$X = \begin{pmatrix} x^1 & \dots & x^p \end{pmatrix},$$

L'ensemble des p vecteurs forme le nuage des variables.

Représentation du nuage des variables



Deux points de vue complémentaires

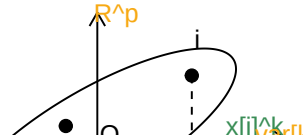
Le nuage des individus C^n

On peut considérer qu'un individu i est un vecteur x_i dans un espace de dimension p. Par convention tous les vecteurs sont des vecteurs colonnes, donc on peut écrire

$$X = \begin{pmatrix} {x_1}^\top \\ \vdots \\ {x_n}^\top \end{pmatrix},$$

L'ensemble des n vecteurs forme le nuage des individus (ce qu'on représente classiquement).

Représentation du nuage des individus



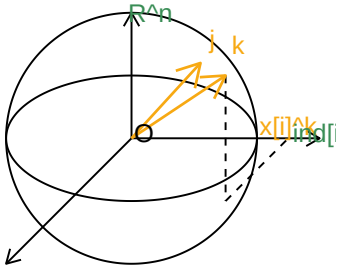
Le nuage des variables C^p

On peut considérer qu'une variable j est un vecteur x^j dans un espace de dimension n et on peut écrire

$$X = \begin{pmatrix} x^1 & \dots & x^p \end{pmatrix},$$

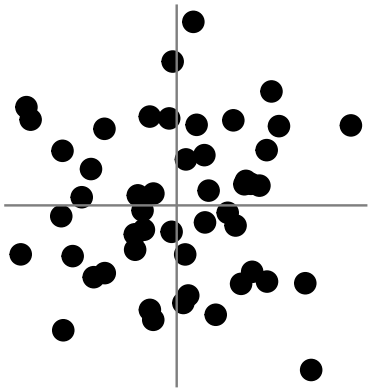
L'ensemble des p vecteurs forme le nuage des variables.

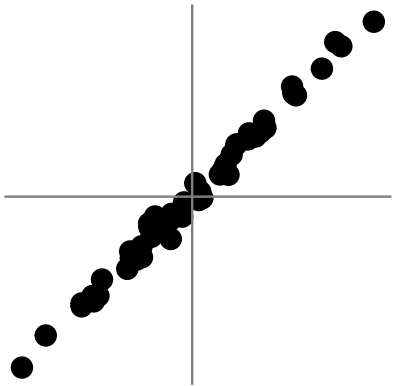
Représentation du nuage des variables



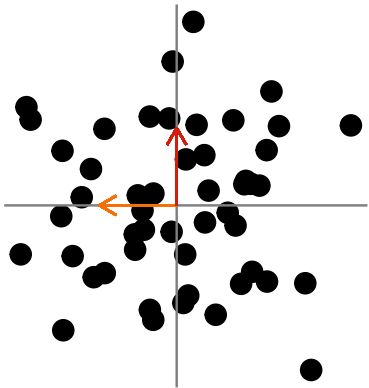
Construction de la base des composantes principales

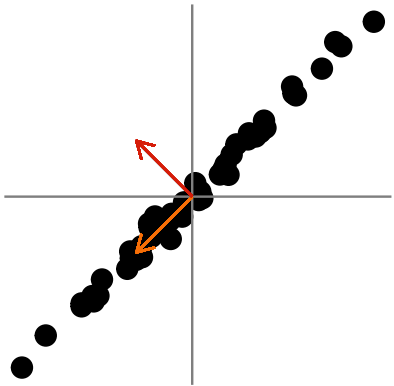
Se donner des intuitions





Se donner des intuitions





Identifier u_1 - Formalisation

- On cherche u_1 tel que I_{u_1} soit minimale mais $I_{u_1} + I_{u_1^\perp} = I$. Minimiser I_{u_1} revient à maximiser $I_{u_1^\perp}$, i.e l'inertie du nuage projeté.
  - Le premier individu se projette en ${x_1}^\top u_1$ sur u_1
  - Le deuxième individu se projette en ${x_2}^\top u_1$ sur u_1
  - ...
- On rappelle que

$$X = \begin{pmatrix} {x_1}^\top \\ \vdots \\ {x_n}^\top \end{pmatrix}.$$

La projection de l'individu i est obtenue en multipliant le vecteur ligne ${x_1}^\top$ par u_1. Le vecteur des coordonnées sur

Maximiser $I_{u_1^\perp}$

sous la contrainte $\|u_1\|$

$$\begin{aligned} I_{u_1^\perp} &= \frac{1}{n}\|Xu_1\|^2 \\ &= \frac{1}{n}(Xu_1)^\top(Xu_1) \\ &= {u_1}^\top \left(\frac{1}{n}X^\top X\right) u_1 \end{aligned}$$

Remarque

- $\frac{1}{n}X^\top X$ est la matrice de covariance, on écrit souvent $\frac{1}{n}X^\top X$ sous la forme $X^\top W X$ (W est une matrice diagonale, dont chaque terme diagonal vaut $1/n$, W_{ii} est le poids attribué à l'observation

Identifier les directions principales

Chercher u_1 tel que $I_{u_1^\perp}$ soit maximale

En se plaçant dans la nouvelle base, posons $v_1 = P^\top u_1$, $\|v_1\| = 1$:
Maximiser ${v_1}^\top D v_1 = \sum_{k=1}^{p} v_{1p}^2 \lambda_p$, sous la contrainte $\sum_{k=1}^{p} v_{1p}^2 = 1$

$$v_1 = (1, 0, \dots, 0)^\top, \quad u_1 = P v_1 = \begin{pmatrix} P_{11} \\ \vdots \\ P_{p1} \end{pmatrix}.$$

u_1 est le premier vecteur propre de $V = X^\top W X$. (la matrice de covariance).

Chercher u_2

On cherche $u_2 \perp u_1$, tel que ${u_2}^\top X^\top W X u_2$ soit maximale.
Posons $v_2 = P^\top u_2$, $\|v_2\| = 1$: Maximiser ${v_2}^\top D v_2 = \sum_{k=1}^{p} v_{2p}^2 \lambda_p$, sous la contrainte $\sum_{k=1}^{p} v_{1p}^2 = 1$ et $v_{1p} = 0$ pour assurer l'orthogonalité avec v_1

$$v_2 = (0, 1, \dots, 0)^\top, \quad u_2 = P v_2 = \begin{pmatrix} P_{12} \\ \vdots \\ U_{p2} \end{pmatrix}.$$

u_2 est le deuxième vecteur propre de de $X^\top W X$.

Mesurer l'information préservée par projection

Sur un axe principal

- Lorsque l'on résume le nuage à sa projection sur un axe factoriel u_k, on ne garde que l'information associée à cet axe soit $I_{u_k{}^\perp} = \lambda_k$.
- La quantité d'information préservée par projection sur l'axe k est donc λ_k.
- La part d'information portée par l'axe k est donnée par $\dfrac{\lambda_k}{\sum_{k=1}^{p} \lambda_k}$

Sur un axe principal

- L'inertie du nuage projeté sur plan k_1, k_2 est donnée par

$$\lambda_{k_1} + \lambda_{k_2}$$

- La part d'information portée par le plan k_1, k_2 est donnée par

$$\frac{\lambda_{k_1} + \lambda_{k_2}}{\sum_{k=1}^{p} \lambda_k}$$

Attention aux unités - Illustration sur les données de manchots

```
library(FactoMineR)

penguins.PCA <- PCA(X = penguins,
                    scale.unit = FALSE, ## should we scale the dat
                    ncp = 4, ## number of components : as many as
                    graph = FALSE, ## no graph right now
                    quali.sup = c(1, 2, 7,8)) ## to indicate the c
penguins.PCA$eig

penguins.PCA$svd$V ## what is named P in the lecture
```

```
      eigenvalue percentage of variance cumulative percentage of var
comp 1 6.465859e+05        9.998932e+01                    99.98932
comp 2 5.058345e+01        7.822325e-03                    99.99715
comp 3 1.610647e+01        2.490736e-03                    99.99964
comp 4 2.353778e+00        3.639929e-04                   100.00000
             [,1]        [,2]        [,3]          [,4]
[1,]  0.004003162  0.31927773  0.94126475 -0.1098470736
[2,] -0.001154327 -0.08684753  0.14449479  0.9856862728
```

Attention aux unités - Illustration sur les données de manchots

```
library(FactoMineR)

penguins.PCA <- PCA(X = penguins,
                    scale.unit = FALSE, ## should we scale the dat
                    ncp = 4, ## number of components : as many as
                    graph = FALSE, ## no graph right now
                    quali.sup = c(1, 2, 7,8)) ## to indicate the c
penguins.PCA$eig

penguins.PCA$svd$V ## what is named P in the lecture
```

```
      eigenvalue percentage of variance cumulative percentage of var
comp 1 6.465859e+05        9.998932e+01                    99.98932
comp 2 5.058345e+01        7.822325e-03                    99.99715
comp 3 1.610647e+01        2.490736e-03                    99.99964
comp 4 2.353778e+00        3.639929e-04                   100.00000
             [,1]        [,2]        [,3]          [,4]
[1,]  0.004003162  0.31927773  0.94126475 -0.1098470736
[2,] -0.001154327 -0.08684753  0.14449479  0.9856862728
```

Attention aux unités - Illustration sur les données de manchots

```
library(FactoMineR)

penguins.PCA <- PCA(X = penguins,
                    scale.unit = FALSE, ## should we scale the dat
                    ncp = 4, ## number of components : as many as
                    graph = FALSE, ## no graph right now
                    quali.sup = c(1, 2, 7,8)) ## to indicate the c
penguins.PCA$eig

penguins.PCA$svd$V ## what is named P in the lecture
```

```
      eigenvalue percentage of variance cumulative percentage of var
comp 1 6.465859e+05        9.998932e+01                    99.98932
comp 2 5.058345e+01        7.822325e-03                    99.99715
comp 3 1.610647e+01        2.490736e-03                    99.99964
comp 4 2.353778e+00        3.639929e-04                   100.00000
             [,1]        [,2]        [,3]          [,4]
[1,]  0.004003162  0.31927773  0.94126475 -0.1098470736
[2,] -0.001154327 -0.08684753  0.14449479  0.9856862728
```

Attention aux unités - Illustration sur les données de manchots normalisées

```
penguins.PCA <- PCA(X = penguins,
                    scale.unit = TRUE, ## should we scale the data
                    ncp = 4, ## number of components : as many as
                    graph = FALSE, ## no graph right now
                    quali.sup = c(1, 2, 7,8)) ## to indicate the c
penguins.PCA$eig

penguins.PCA$svd$V ## what is named P in the lecture
```

```
      eigenvalue percentage of variance cumulative percentage of varia
comp 1  2.7453557             68.633893                       68.63389
comp 2  0.7781172             19.452929                       88.08682
comp 3  0.3686425              9.216063                       97.30289
comp 4  0.1078846              2.697115                      100.00000
            [,1]       [,2]       [,3]       [,4]
[1,]  0.4537532 0.60019490 -0.6424951 -0.1451695
[2,] -0.3990472 0.79616951  0.4258004  0.1599044
[3,]  0.5768250 0.00578817  0.2360952  0.7819837
```

Choix de la distance

L'ACP normée (ACP sur les données centrées et réduites) peut-être envisagée comme une ACP avec une autre distance que la distance euclidienne.

Une autre manière de présenter la même approche est de dire qu'on change la métrique utilisée

Definition (métrique)

Une métrique M permet de définir une distance entre les observations (ainsi, M est une matrice de $\mathbb{R}^p \times \mathbb{R}^p$ symétrique, définie et positive).

Calcul de distance

Soient $x_1 \in \mathbb{R}^p$ et $x \in \mathbb{R}^p$, la distance entre x_1 et $x_2$pour la métrique M est

$$d_M(x_1, x_2)^2 = \|x_1 - x_2\|_M^2 = (x_1 - x_2)^\top M(x_1 - x_2).$$

Choix de la distance

Exemple I_p | Distance normalisant les variables

Si $M = I_p$,

$$d_M(x_1, x_2)^2 = \|x_1 - x_2\|_M^2 = (x_1 - x_2)^\top I_p (x_1 - x_2) = \sum_{k=1}^{p} (x_{1k} - x_{2k})^2.$$

Choix de la distance

Si M est diagonale est $M_{ii} = 1/s_i^2$ où s_i^2 est la variance de la variable i,

$$d_M(x_1, x_2)^2 = (x_1 - x_2)^\top M (x_1 - x_2) = \sum_{k=1}^{p} \frac{(x_{1k} - x_{2k})^2}{s_k^2} = \sum_{k=1}^{p} \left(\frac{x_{1k}}{s_k} - \frac{x_{2k}}{s_k} \right)^2 .$$

Dans une ACP normée on s'intéresse donc aux valeurs propres de la matrice $M^{1/2} X^\top W X M^{1/2}$, il s'agit de la matrice de corrélation.

On note V la matrice de covariance et on va donc travailler sur $M^{1/2} V M^{1/2}$

Identifier les directions principales pour une métrique quelconque M

Maximiser $I_{u_1^\perp}$

sous la contrainte $\|u_1\|$

$$\begin{aligned} I_{u_1^\perp} &= \frac{1}{n}\|Xu_1\|_M^2 \\ &= \frac{1}{n}(Xu_1)^\top M(Xu_1) \\ &= {u_1}^\top M^{1/2}\left(\frac{1}{n}X^\top X\right)M^{1/2}u_1 \end{aligned}$$

D'apères ce qui précède u_1 est le premier vecteur propre de $M^{1/2}VM^{1/2}$.
Le changement de métrique a un impact sur la matrice à diagonaliser mais pas sur la logique de construction.

Etude du nuage des individus

Definition (Composantes principales)

Les coordonnées des n observations sur les p axes factoriels sont groupées dans la matrice C: c_{ik} est la coordonnée de l'observation i sur l'axe Δ_{u_k}. La k-ème composante principale est la colonne k de la matrice C, notée C^k.

$$C = [C^1 | \dots | C^p] \text{ avec } C^k = \begin{pmatrix} c_{1k} \\ \vdots \\ c_{nk} \end{pmatrix}.$$

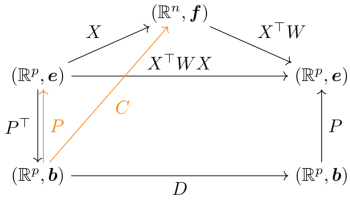
On a les expressions suivantes

$$C^k = Xu_k \text{ et } C = XP,$$

où P désigne la matrice de changement base, i.e la matrice contenant les vecteurs propres.

Représentation des individus - Composantes principales

Vectoriellement | **Visuellement** | Remarques



Représentation des individus - Composantes principales

- Les C^k sont des combinaisons linéaires des variables de départ.
- Elles sont centrées, de variance $\lambda_k = \sum_{i=1}^{n} w_i c_{ik}^2$ et non-corrélées 2 à 2.
- Les C^k sont vecteurs propres (non unitaires) de $\frac{1}{n} X W X^\top$ de valeur propre λ_k.

Représentation des manchots

```
X <- penguins |>
  mutate(year = as.factor(year))|>  ## year willnot be considered
  select(where(is.numeric)) |>      ## select all numeric columns
  mutate_all(list(scale2)) |>          ## and scale them
  as.matrix()

n <- nrow(X) # number of individuals
d <- ncol(X)

penguins_svd <- svd( 1/n * t(X)%*% X ) # to get P and D from t(X)W

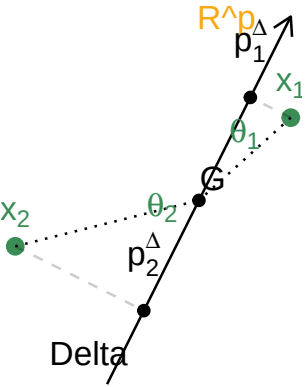
## eigenvalues
penguins_eigenvalue <- penguins_svd$d

P <- penguins_svd$v
cp <- X %*% P
head(cp[, 1:2])
cat("\n")
head(penguins.PCA$ind$coord[,1:2])
```

Qualité de la représentation d'un individu

- Même avec ces précautions, on déforme le nuage de points
- Certains sont plus déformés que d'autre, il faut les identifier

Un individu est d'autant moins déformé qu'il est proche du plan sur lequel on le projette, ce qui est donné par l'angle entre le vecteur initial et le vteur projeté



$$< x_i, u_1 > = \|x_i\| \|u_1\| cos(\theta_i)$$
$$= {x_i}^\top u_1, \quad (\text{ou } {x_i}^\top M u_1 \text{avec une au}$$

$$\cos^2(\theta_i) = \frac{({x_i}^\top u_1)^2}{\|x_i\|^2}$$

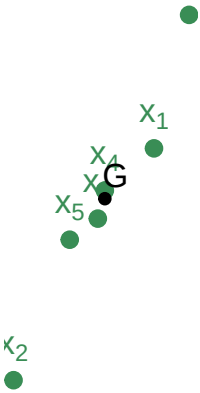
Interprétation: plus $\cos^2(\theta_i)$ est proche de 1, mieux l'individu est représenté

Contribution d'un individu à la définition de l'axe

- Les individus sont plus ou moins important dans la définition des axes

Contribution d'un individu à la définition de l'axe

Intuitivement | Formellement



Quels sont les points qui vont le plus contribuer à la détermination des axes ?

Contribution d'un individu à la définition de l'axe

Intuitivement | **Formellement**

La contribution relative de l'observation x_i à la construction de l'axe principal k est la part d'inertie de l'axe k expliquée par x_i donnée par

$$Ctr(i,k) = \frac{1}{n}\frac{c_{ik}^2}{\lambda_k}.$$

En effet $\lambda_k = \frac{1}{n}\sum_{i=1}^{n} c_{ik}^2$ (ie. la variance du nuage projeté).

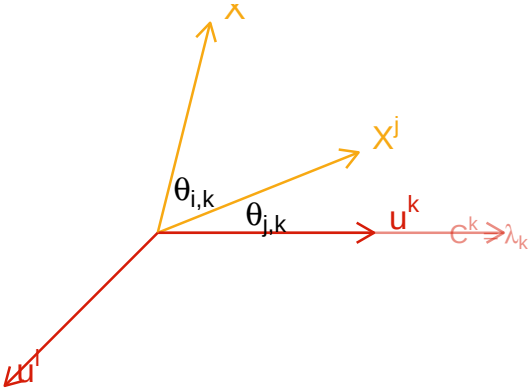
Remarque : si les individus ont des poids w_i alors

$$Ctr(i,k) = \frac{w_i c_{ik}^2}{\lambda_k}.$$

Etude des variables

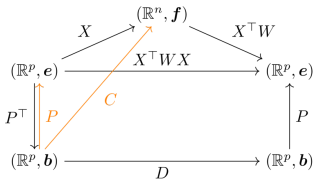
Qualité de la représentation d'une variable sur un plan factoriel

Intuitivement | Formellement



Qualité de la représentation d'une variable sur un plan factoriel

Intuitivement | **Formellement**



- Une variable est bien représentée sur l'axe k si l'angle entre cette variable et la composante C^k est petit, son cosinus est proche de 1 ou -1.

Or

$$< X^j, C^k >= \|X^j\| \|C^k\| cos(\theta_{jk})$$

$$\begin{aligned} < X^j, C^k > &=< (CP^\top)^j, C^k > \\ &= \underbrace{((CP^\top)^j)^\top}_{=(PC^\top)_j} C^k \end{aligned}$$

Ainsi $< X^j, C^k >$ est le $j^{\text{ème}}$ terme du vecteur $PC^\top C^k$, or $C^\top C$ est

Ajouter des informations supplémentaires

Il est possible d'ajouter des informations supplémentaires

Des individus supplémentaires qui ne seront pas utilisés pour construire les axes

Si on veut ajouter un nouvel individu x_{new}

- on calcule $x_{new} - g$, le point centré (et potentiellement on divise par l'écart type des variables calculés sur le jeu de données initial)
- On projette sur les axes principaux : $(x_{new} - g)^\top u_k$

Une variable supplémentaire

Si on souhaite ajouter une nouvelle variable $x^{new} = (x_1^{new}, ..., x_n^{new})^\top \in \mathbb{R}^n$

- On soustrait sa moyenne $\tilde{x}^{new} = x^{new} - m^{new}$, $m^{new} = \frac{1}{n}\sum_{i=1}^n x_i^{new}$ (ou $m^{new} = \sum_{i=1}^n w_i x_i^{new}$ si toutes les observations n'ont pas le même poids)
- On projette $\tilde{x}^{new}$ sur u_k,

$$Cor(\tilde{x}^{new}, u_k) = \frac{(\tilde{x}^{new})^\top W u_k}{\|\tilde{x}^{new}\|}$$

Retournons à nos manchots

```
penguins.PCA <- PCA(X = penguins,
                    scale.unit = TRUE, ## should we scale the data
                    ncp = 4, ## number of components : as many as
                    quali.sup = c(1, 2, 7,8)) ## to indicate the c

 # library(Factoshiny)
 # PCAshiny(penguins)
```

Comprendre les données du Doubs

Présentation des données

L'exemple des caractéristiques du Doubs

On a mesuré les caractéristiques physico chimiques sur 30 sites différents le long de la rivière Doubs.

Les 6 premières lignes (parmi 30) du jeu de données doubs.env

```
# A tibble: 30 x 11
   das  alt  pen  deb   pH  dur  pho  nit  amm  oxy
 <dbl> <int> <dbl> <dbl> <dbl> <int> <dbl> <dbl> <dbl> <dbl>
1  0.3   934  48   0.84  7.9   45  0.01  0.2  0.1  12.2
2  2.2   932   3   1     8     40  0.02  0.2  0.1  11.9
3 10.2   914   3.7 1.8   8.3   52  0.05  0.2  0.1  10.5
4 18.5   854   3.2 2.53  8     72  0.1   0.2  0.1  11.1
5 21.5   849   2.3 2.64  8.1   84  0.38  0.2  0.1  11.3
6 32.4   846   3.2 2.86  7.9   60  0.2   0.2  0.1  10.2
# i 24 more rows
```

- das : distance à la source (km),
- alt : altitude (m)
- pen : la pente (déniv pour 1000 m),
- deb : le débit ($m^3.s^{-1}$)
- pH : le pH de l'eau,
- dur : la concentration en calcium ($mg.L^{-1}$),
- pho : la concentration en phosphate ($mg.L^{-1}$),
- nit : concentration en nitrate ($mg.L^{-1}$),
- amn : concentration en ammonium ($mg.L^{-1}$),
- oxy : concentration d'oxygène dissous ($mg.L^{-1}$),

Analyse par ACP

- Poids des individus ?
- Quelle distance entre les variables ?
- Lancer l'analyse
  - quelles sont les composantes intéressantes (règle empririque du choix du nombre d'axes) ?
  - quelles informations sont visibles sur le premier plan factoriel ?
  - Que peut on dire des liens entre les variables ?
  - A votre avis quels sites contribuent le plus à la formation de l'axe 1 ?
  - Que peut on dire du pH ?

L'ACP comme une méthode de compression

Ne garder que l'information pertinente

On a utilisé l'ACP comme une technique de visualisation, mais on peut sen servir comme une technique de compression (avec perte). Il suffit de ne garder que les première composantes principales.

L'exemple sur une image

Point Technique

Matrice d'inertie

Revisiter l'inertie

L'inertie du nuage de points est définie comme

$$I = \sum_{i=1}^{n} w_i \|x_i - g\|_M^2$$

On a considéré des variables centrées donc $g = 0$.

- Or

$$I = \sum_{i=1}^{n} w_i x_i^\top M x_i = tr(\sum_{i=1}^{n} w_i x_i^\top M x_i)$$

$$= tr(\sum_{i=1}^{n} M x_i w_i x_i^\top) \quad \text{(commutatitvité de la trace)}$$

$$= tr(M \sum_{i=1}^{n} x_i w_i x_i^\top)$$

Exemple sur les cas présentés

- Dans le cas de l'ACP, la matrice V est la matrice de covariance et $M = Id$,
- Dans le cas de l'ACP normée , la matrice V est la matrice de covariance et $M = Diag(s_k^{-2})$,

Bilan

Ce que vous pensez devoir retenir

- l'ACP permet de mettre en valeur l'information principale contenu dans un jeu de données
  - les relations entre variables
  - les proximités entre individus
- Cette méthode permet d'obtenir une projection sur queluqes axes indépendants et bien choisis, au sens ou ils résument le mieux l'information
- Techniquement l'ACP consiste à diagonaliser la matrice de covariance
- Les axes sont définis par les vecteurs propres de la matrice

$$X^\top W X$$

- Ils sont rangés par ordre d'importance décroissante, au sens où le premier est celui qui préserve le plus l'inertie du nuage projeté (i.e a la plus grande valeur propre)
- Il faut adapter la métrique au probleme

- l'information portée par un axe est mesurée par la valeur propre associé à