ACP : données manquantes, imputation, imputation multiple

Marie-Pierre Etienne

https://marieetienne.github.io/MAF/

2026-11-10

Introduction

ACP sur données réelles : rarement complètes

Constat empirique

- Les tableaux analysés par ACP sont souvent incomplets :
  - mesures manquantes,
  - variables coûteuses ou difficiles à acquérir,
  - protocoles hétérogènes.

Exemples concrets

- Environnement : stations $\times$ variables physico-chimiques $\rightarrow$ capteurs défaillants, données non synchrones.
- Écologie : espèces $\times$ traits fonctionnels $\rightarrow$ traits manquants pour certaines espèces.
- Socio-économie : individus $\times$ indicateurs $\rightarrow$ non-réponse partielle aux questionnaires.

Objectif de l'ACP

Résumer la structure de dépendance *globale* entre variables

$\rightarrow$ difficile si le tableau est incomplet.

Le suivi d'ozone à Rennes

112 mesures journalières de variables météorologiques (vitesse du vent, température, précipitations, etc.) ainsi que la concentration d'ozone, relevées à Rennes (France) durant l'été 2001.

11 variables continues et 2 variables catégorielles comportant 2 ou 4 modalités.

Cet exemple est issu du package R `missMDA`

```
  maxO3 T9 T12 T15 Ne9 Ne12 Ne15 Vx9 Vx12 Vx15 maxO3v vent pluie
1    13  9  16  19   6   11   13   6   14   14      5   11     8
```

Attitude 1 : suppression des individus incomplets

Approche naïve - Conserver uniquement les lignes sans valeurs manquantes.

Conséquences - Forte réduction de la taille de l'échantillon. - Perte d'information multivariée. - Biais potentiel si les manquants ne sont pas MCAR.

Une ACP « propre » sur peu de données peut être moins informative qu'une ACP bien traitée sur des données incomplètes.

Exemple Ozone

```
    n
1 112
   n
1 30
 0  1  2  3  4  5
30 38 30 10  3  1
```

C'est bien dommage !!!

Attitude 2 : faire avec ce qu'on a

vision schématique

$$\mathbf{X} = \begin{pmatrix} x_{11} & x_{12} & \bullet & x_{14} \\ x_{21} & \bullet & x_{23} & x_{24} \\ x_{31} & x_{32} & x_{33} & \bullet \end{pmatrix}$$

• : valeur manquante

On peut calculer une matrice de corrélation à partir des couples de données disponibles.

Problème

- Les corrélations sont calculées sur des sous-échantillons différents.
- La matrice de covariance peut devenir incohérente.

Conséquence

- Axes principaux instables ou difficilement interprétables.

La question centrale

Question statistique

- Comment estimer un sous-espace principal pertinent à partir d'un tableau incomplet $\mathbf{X}_{obs}$?

Deux grandes familles de réponses

1. Compléter les données (imputation)
2. Modéliser directement la structure latente (ACP comme modèle factoriel)

Les deux approches sont étroitement liées.

Formalisation

Données manquantes et ACP : cadre formel

Données et notations

- $\mathbf{X} \in \mathbb{R}^{n \times p}$: matrice de données (souvent centrée, éventuellement réduite).
- $\mathbf{R} \in 0, 1^{n \times p}$: indicateurs de données manquantes :

$$r_{ij} = \begin{cases} 1 & \text{si } x_{ij} \text{ est observé} \\ 0 & \text{si } x_{ij} \text{ est manquant} \end{cases}$$

- Décomposition : $\mathbf{X} = (\mathbf{X} * obs, * \mathbf{X} mis)$.

ACP complète

$$\hat{\Sigma} = \frac{1}{n} \mathbf{X}^\top \mathbf{X}$$

Mécanismes des données manquantes

- **MCAR** : $P(\mathbf{R} \mid \mathbf{X}) = P(\mathbf{R})$
- **MAR** : $P(\mathbf{R} \mid \mathbf{X}) = P(\mathbf{R} \mid \mathbf{X} * obs)$
- **MNAR** : $P(* \mathbf{R} \mid \mathbf{X})$ dépend de $\mathbf{X} mis$

Imputation de données

Imputation simple : principe et propriétés

Principe

- Construire $\tilde{\mathbf{X}}$ par remplacement **ponctuel** des valeurs manquantes. - Appliquer ensuite une ACP standard sur $\tilde{\mathbf{X}}$.

Quel remplacement ponctuel ?

- **Moyenne** (si centrée : 0) : $\tilde{x}_{ij} = \bar{x}_j$
- **Régression** : On ajuste un modèle sur les données disponibles

$$x_{ij} = \beta_0^j + * \sum_{k \neq j} \beta_k^j x_{ik} + \varepsilon_i^j$$

et on prédit

$$\hat{x}_{ij}^{miss} = \beta_0^j + * \sum_{k \neq j} \beta_k^j x_{ik}$$

- **ACP itérative / EM-PCA (idée)** : alternance (estimation sous-espace) / (reconstruction) jusqu'à convergence. (Hors programme nécessite les

Imputation multiple et ACP

Principe - Générer (M) complétions :

$$\tilde{\mathbf{X}}^{(1)}, \ldots, \tilde{\mathbf{X}}^{(M)}$$

en simulant $\mathbf{X} * mis$ selon une loi approchant $p(\mathbf{X}mis \mid \mathbf{X}_{obs})$ (souvent sous MAR + modèle).

Analyse - ACP sur chaque $\tilde{\mathbf{X}}^{(m)} \Rightarrow$ (M) jeux (valeurs propres, charges, scores).

Combinaison (une option simple)

$$\bar{\Sigma} = \frac{1}{M} \sum_{m=1}^{M} \hat{\Sigma}^{(m)}$$

puis ACP de $\bar{\Sigma}$.

- diagnostics : variabilité inter-imputations des charges/axes.

Pratiquement

1) Diagnostiquer les manquants - Taux global + par variable/individu ; structure (blocs, monotone, etc.). - Tester/argumenter (au moins qualitativement) MCAR vs MAR vs MNAR.

2) Pré-traitement cohérent - Décider centrage / réduction (important en ACP sur corrélation). - Idéalement : inclure ce pré-traitement *dans* le modèle d'imputation (ou le reproduire à l'identique après imputation).

3) Choisir la stratégie - **Exploration rapide** : imputation simple (moyenne / kNN / ACP itérative). - **Inférence / reporting** : imputation multiple (MI), surtout sous MAR.

4) Estimer l'ACP - Sur $\tilde{\mathbf{X}}$ (simple) ou sur chaque $\tilde{\mathbf{X}}^{(m)}$ (IM). - Attention à l'alignement des axes si besoin (indétermination du signe / rotations).

5) Diagnostics & sensibilité - Stabilité des charges/axes (bootstrap ou IM). - Sensibilité au nombre de composantes q, au modèle d'imputation, et (si plausible) scénarios MNAR.

Deux mots sur l'ACP comme modèle factoriel (vue probabiliste)

Modèle - Pour l'individu (i) :

$$\mathbf{x}_i = \mu + \mathbf{L}\mathbf{z}_i + \varepsilon_i$$

où - $\mathbf{z}_i \in \mathbb{R}^q$: facteurs latents (scores), - $\mathbf{L} \in \mathbb{R}^{p \times q}$: charges (loadings), - $\varepsilon_i \sim \mathcal{N}(\mathbf{0}, \sigma^2 \mathbf{I}_p)$ (hypothèse "bruit isotrope").

Lien avec l'ACP - Si $\mathbf{z}_i \sim \mathcal{N}(0, \mathbf{I}_q)$, alors :

$$\mathrm{Cov}(\mathbf{x}_i) = \mathbf{L}\mathbf{L}\top + \sigma 2\mathbf{I}_p$$

- L'estimation des paramètres (par maximum de vraisemblance ou EM, cf cours statistique inférentielle) mène à un sous-espace proche de celui de l'ACP (cas $\sigma^2 I$: "probabilistic PCA").

Pourquoi utile avec des manquants ? - Le cadre probabiliste donne naturellement $p(\mathbf{X}^{mis} \mid \mathbf{X}obs)$. - EM : E-step (espérances conditionnelles des facteurs et/ou manquants), M-step (mise à jour de $\mathbf{L}, \sigma^2$).

Exemple de mise en œuvre (R) : ACP itérative vs imputation multiple