Analyse Factorielle des Correspondances

Marie-Pierre Etienne

https://marieetienne.github.io/MAF/

2026-11-10

Introduction

Les manchots comme exemple introductif

L'étude sur les manchots de Palmer s'intéresse à diverses espèces de manchots sur diverses îles.

Question : est ce que les différentes espèces sont présentes de la même manière sur les différentes îles ?

island	Adelie	Chinstrap	Gentoo
Biscoe	44	0	119
Dream	55	68	0
Torgersen	47	0	0

Avec peu d'espèces, et peu d'îles, il est facile de constater que les espèces ne sont pas présentes de la même manière sur toutes les îles.

Conclusion : Il y a un lien entre espèce et île où le manchot est observé.

Exemple causes de décès en France

Le fichier des décès en France contient pour 65 causes de décès le nombre cumulés de morts en 1979 et 2006 par tranche d'age, puis dans Les 65 lignes suivantes uniquement ce cumul pour 1979, puis pour 2006 et enfin pour chaque année le nombre de décès par tranche d'ages, toutes causes confondues.

Cause	X0.1	X1.4	X5.14	X15.24	X25.34
Abus alcool et psychose alcoolique	0	0	0	29	214
Accidents de transport	52	194	655	4,653	2,451
Arthrite rhumatoïde et os-téoarthrite	0	0	3	2	6
Asthme	9	6	9	29	39

Cadre général

L'analyse factorielle des correspondances (AFC) est une méthode factorielle pour l'exploration statistique d'une table de contingence définie par deux variables qualitatives.

Objectif : Le but est d'étudier la liaison entre ces deux variables qualitatives(notamment quelles associations de modalités sont sur-représentées).

> La terminologie analyse des correspondances vient du fait que l'on analyse un tableau mettant en correspondance deux ensembles:
> - L'ensemble des lignes du tableau,
> - et l'ensemble des colonnes du tableau.

Les données

On considère deux variables qualitatives A et B ayant respectivement I ($a_1, \dots, a_I$) et J ($b_1, \dots, b_J$) modalités. Ces variables sont observées simultanément sur n individus affectés de poids identiques $1/n$.

Les données se présentent initialement sous la forme d'un tableau à n lignes et 2 (ou 3 colonnes si on ajoute un identifiant).

Exemple de table de données

ID	A	B
001	a_1	b_2
002	a_1	b_2
003	a_2	b_2
004	a_2	b_1
005	a_1	b_1
005	a_1	b_3

Il est fréquent de recoder (ou même de récolter) les variables sous la forme d'un tableau disjoinctif complet. A chaque variable ℓ, on associe une table X^ℓ, à n et autant de colonnes que la variable ℓ, qui contient pour chaque individu k, à la colonne m un 1 si l'individu k possède la modalité m et un 0 sinon.

Sur l'exemple précédent

$$\mathbf{X} = \begin{pmatrix} \mathrm{X}^1 & \mathrm{X}^2 \end{pmatrix}$$

$$\mathbf{X} = \begin{array}{c} \begin{matrix} \mathrm{a}_1 & \mathrm{a}_2 & \mathrm{b}_1 & \mathrm{b}_2 & \mathrm{b}_3 \end{matrix} \\ \begin{pmatrix} 1 & 0 & 0 & 1 & 0 \\ 1 & 0 & 0 & 1 & 0 \\ 0 & 1 & 0 & 1 & 0 \\ 0 & 1 & 1 & 0 & 0 \\ 1 & 0 & 1 & 0 & 0 \\ 1 & 0 & 0 & 0 & 1 \end{pmatrix} \end{array}$$

Il s'agit de la matrice K à I lignes et J colonnes, dont le terme général k_{ij} compte le nombre d'individus possédant simultanément les carcatéristiques a_i et b_j.

$$K = [k_{ij}] \quad \begin{matrix} i = 1, \dots, I \\ j = 1, \dots, J \end{matrix} .$$

Remarque 1

$$K = (X^1)^\top X^2$$

Remarque 2

Sur l'exemple précédent

$$K = \begin{pmatrix} 1 & 2 & 1 \\ 1 & 1 & 0 \end{pmatrix}$$

$$X^\top X = \begin{pmatrix} 4 & 0 & 1 & 2 & 1 \\ 0 & 2 & 1 & 1 & 0 \\ 1 & 1 & 2 & 0 & 0 \\ 2 & 1 & 0 & 3 & 0 \\ 1 & 0 & 0 & 0 & 1 \end{pmatrix}$$

Quelques notations

Formellement

On note les effectifs

- $k_{i+} = \sum_{j=1}^{J} k_{ij}$ le nombre total d'individus ayant la modalité i
- $k_{+j} = \sum_{i=1}^{I} k_{ij}$ le nombre total d'individus ayant la modalité j
- $n = \sum_{i=1}^{I} \sum_{j=1}^{J} k_{ij}$
- les proportions $f_{ij} = k_{ij}/n$,

Et les proportions marginales

- $f_{i+} = \sum_{j=1}^{J} f_{ij}$ la proportion d'individus ayant la modalité i
- $f_{+j} = \sum_{i=1}^{I} f_{ij}$ la proportion d'individus ayant la modalité j
- $f_{++} = 1$

Sur l'exemple

$$K = \begin{array}{ccc||c} 1 = k_{11} & 2 = k_{12} & 1 = k_{13} & E_1 \\ 1 = k_{21} & 1 = k_{22} & 0 = k_{23} & 2 \\ \hline\hline 2 = k_{+1} & 3 = k_{+2} & 1 = k_{+3} & \end{array}$$

Modèle d'indépendance

On dit que deux variables A et B sont non liées si et seulement si

$$\forall (i,j) \in \{1,\dots,I\} \times \{1,\dots,J\} : \; k_{ij} = \frac{k_{i+}k_{+j}}{n}$$

Cette notion est bien sûr liée à l'indépendance en probabilité. En effet, deux variables aléatoires A et B sont indépendantes ssi

$$\underbrace{\mathbb{P}(A = i \cap B = j)}_{\text{estimée par } \frac{k_{ij}}{n} = f_{ij}} = \underbrace{\mathbb{P}(A = i)}_{\text{estimée par } \frac{k_{i+}}{n} = f_{i+}} \times \underbrace{\mathbb{P}(B = j)}_{\text{estimée par } \frac{k_{+j}}{n} = f_{+j}} \quad , \forall (i,j)$$

On souhaite étudier la liaison entre A et B à partir de nos observations.

La représentation graphique des profils-lignes ou des profils-colonnes, au moyen de diagrammes en barres parallèles, ainsi que le calcul de coefficients de liaison (Cramer) donnent une première idée de la variation conjointe des deux variables.

Le test du χ^2 permet de plus de s'assurer du caractère significatif de cette liaison.

Test d'indépendance du χ^2

(cf cours sur les tests du 2d semestre)

- l'hypothèse nulle est H_0: A et B sont indépendantes,
- l'hypothèse alternative est H_1: A et B ne sont pas indépendantes.

La statistique de test est

$$T = \sum_{i=1}^{I}\sum_{j=1}^{J} \frac{\left(\text{Effectif observé}_{ij} - \text{Effectif ettendu}_{ij}\right)^2}{\text{Effectif attendu}_{ij}} = \sum_{i=1}^{I}\sum_{j=1}^{J} \frac{(nf_{ij} - nf_{i+}f_{+j})^2}{nf_{i+}f_{+j}}$$

Pour des grandes valeurs de n, et si H_0 est vraie,

$$T \sim \chi^2_{(I-1)(J-1)}.$$

Si T est grand, on rejette H_0.

La force de la dépendance est capturée par Φ^2

Probabilité conditionnelle

Rappel

$$P(A = i|B = j) = \frac{P(A = i, B = j)}{P(B = j)}$$

Déclinaison sur les fréquences

- $\frac{f_{ij}}{f_{i+}}$ est la fréquence d'apparition de la modalité j au sein de la population $A = i$. Si A et B sont indépendantes, alors $\frac{f_{ij}}{f_{i+}} = f_{+j}$
- $\frac{f_{ij}}{f_{+j}}$ est la fréquence d'apparition de la modalité $i$au sein de la population $B = j$. Si A et B sont indépendantes, alors $\frac{f_{ij}}{f_{+j}} = f_{i+}$

Profils-lignes et profils-colonnes

Profils-lignes N_I

Le tableau des profils-lignes X est le tableau des fréquences conditionnelles de la modalité j de B sachant la modalité i de A:

Profils-lignes N_I

$$X = \left(\frac{f_{ij}}{f_{i+}}\right) \quad \begin{matrix} i = 1, \dots, I \\ j = 1, \dots, J \end{matrix}$$

Ainsi avec les notations du cours d'ACP

$$X = \begin{pmatrix} x_1^\top \\ \vdots \\ x_i^\top \\ \vdots \\ x_I^\top \end{pmatrix} \text{ avec } x_i = \begin{pmatrix} f_{i1}/f_{i+} \\ \vdots \\ f_{ij}/f_{i+} \\ \vdots \\ f_{iJ}/f_{i+} \end{pmatrix} \in \mathbb{R}^J.$$

A chaque ligne i, on fait correspondre un point dans $\mathbb{R}^J$ dont la j^{ème} coordonnée vaut f_{ij}/f_{i+}.

Profils-lignes N_I

Chaque point i est affecté du poids f_{i+}.

Le point moyen G_I est défini par

$$G_I = \sum_{i=1}^{I} f_{i+} x_i = (f_{+1}, \dots, f_{+J})$$

On a le nuage de points X, complété par les poids f_{i+}.

La distance dont on munit l'espace $\mathbb{R}^J$ consiste à donner un poids $1/f_{+j}$ à la j^{ème} dimension, la distance au carré (dite distance du χ^2) entre les points i_1 et i_2 est définie par

$$d^2_{\chi^2}(x_{i_1}, x_{i_2}) = \sum_{j=1}^{J} \frac{1}{f_{+j}} \left(\frac{f_{i_1 j}}{f_{i_1 +}} - \frac{f_{i_2 j}}{f_{i_2 +}} \right)^2$$

Ce choix est motivé par l'inertie du point x_i par rapport au centre de garivité G_I, en effet

$$Inertie_{G_I}(x_i) = f_{i+} d^2_{\chi^2}(x_i, G_I) = f_{i+} \sum_{j=1}^{J} \frac{1}{f_{+j}} \left(\frac{f_{ij}}{f_{i+}} - f_{+j} \right)^2 = \sum_{j=1}^{J} \frac{(f_{ij} - f_{i+} f_{+j}}{f_{i+} f_{+j}}$$

Ainsi l'inertie totale du nuage par rapport à G_I vaut

Profils-colonnes

Dans le tableau de contingence, lignes et colonnes jouent des rôles symétriques

Le tableau des profils-colonnes X est le tableau des fréquences conditionnelles de la modalité i de A sachant la modalité j de B:

$$X = \left(\frac{f_{ij}}{f_{+j}}\right) \quad \begin{matrix} i = 1, \dots, I \\ j = 1, \dots, J \end{matrix}$$

Ainsi avec les notations du cours d'ACP

$$X = \begin{pmatrix} x^1 & \dots & x^j & \dots & x^J \end{pmatrix} \text{ avec } x^j = \begin{pmatrix} f_{1j}/f_{+j} \\ \vdots \\ f_{ij}/f_{+j} \\ \vdots \\ f_{Ij}/f_{+j} \end{pmatrix} \in \mathbb{R}^I.$$

A chaque colonne j, on fait correspondre un point dans $\mathbb{R}^I$ dont la i^{ème} coordonnée vaut f_{ij}/f_{+j}.

Chaque point j est affecté du poids f_{+j}.

Le point moyen G_J est défini par

$$G_J = \sum_{j=1}^{J} f_{+j}\, x^j = (f_{1+}, \dots, f_{I+})$$

On a le nuage de points X, complété par les poids f_{+j}.

La distance dont on munit l'espace $\mathbb{R}^I$ consiste à donner un poids $1/f_{i+}$ à la i^{ème} dimension, la distance au carré (dite distance du χ^2) entre les points j_1 et j_2 est définie par

$$I_{G_J}(x^j) = f_{+j} d^2_{\chi^2}(x^j, G_J) = f_{+j} \sum_{i=1}^{I} \frac{1}{f_{i+}} \left(\frac{f_{ij}}{f_{+j}} - f_{i+} \right)^2 = \sum_{i=1}^{I} \frac{\left(f_{ij} - f_{i+} f_{+j}\right)^2}{f_{i+} f_{+j}}.$$

Ainsi l'inertie totale du nuage par rapport à G_I vaut

$$I_{G_J} = \sum_{i=1}^{I} \sum_{j=1}^{J} \frac{\left(f_{ij} - f_{i+} f_{+j}\right)^2}{f_{i+} f_{+j}} = \Phi^2$$

L'inertie mesure l'écart à l'indépendance. L'étude du nuage N_J rend compte de la structure des données.

ACP des nuages lignes et colonnes

Réalisé une l'ACP profils lignes.

- L'origine des axes est placée au centre G_I du nuage N_I
- On recherche une suite d'axes othogonaux d'inertie maximale
- Le nuage est projeté sur ces axes et on représente ces projections en associant deux axes pour créer un plan.
- la proximité entre deux profils lignes, s'exprime par la même manière de s'écarter de l'indépendance.

ACP des nuages lignes et colonnes

Réalisé une l'ACP profils colonnes

- L'origine des axes est placée au centre G_J du nuage N_J
- On recherche une suite d'axes othogonaux d'inertie maximale
- Le nuage est projeté sur ces axes et on représente ces projections en associant deux axes pour créer un plan.
- la proximité entre deux profiils colonne, s'exprime par la même manière de s'écarter de l'indépendance.

ACP des nuages lignes et colonnes

Puisque le nuage N_I se place dans l'espace $\mathbb{R}^J$, on peut penser qu'il faut J axes pour tout représenter. Mais

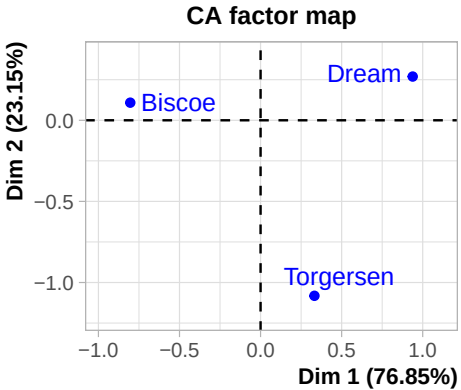
- La somme des coordonnées d'un profil vaut 1, on est donc dans un espace de dimension $\mathbb{R}^{J-1}$
- Le nuage N_I centré comporte I lignes, il est possible de les représenter tous avec $I-1$ dimensions

On représente donc toute l'information avec $\min(I-1, J-1)$ axes.

Représentation

Représentation des profils lignes | Représentation des profils colonnes

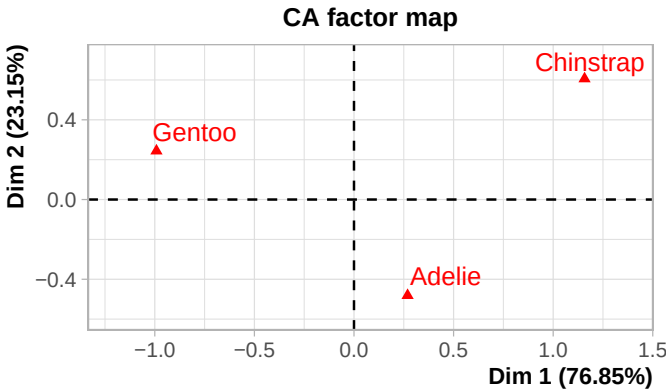
```
penguins.CA <- CA(penguin_cont, graph = FALSE)
plot(penguins.CA, invisible = "col" )
```



Représentation

Représentation des profils lignes | **Représentation des profils colonnes**

```
plot(penguins.CA, invisible = "row" )
```



Représentation jointe lignes et colonnes

- Les deux nuages N_I et N_J ont la même inertie
- L'inertie projetée sur l'axe ℓ est données par l'inertie du nuage projeté sur cet axe.
  - concernant les profils lignes $\sum_i^I f_{i+} \|OH_i^\ell\|^2 = \lambda_\ell$
  - concernant les profils colonnes $\sum_j^J f_{+j} \|OH_j^\ell\|^2 = \lambda_\ell$ Ainsi les deux nuages ont la même inertie projetée sur chaque axe.
- Lien entre coordonnées des lignes et des colonnes : relations pseudo-barycentriques suivantes pour $\ell = 1, \dots, min(I-1, J-I)$

$$F_\ell(i) = \frac{1}{\sqrt{\lambda_\ell}} \sum_{j=1}^{J} \frac{f_{ij}}{f_{i+}} G_{\ell(j)},$$

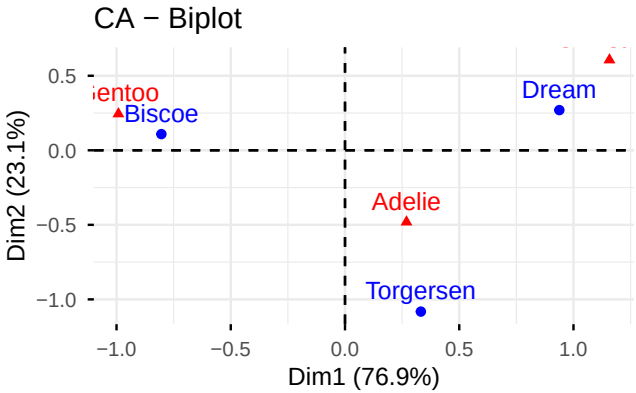
$$G_\ell(j) = \frac{1}{\sqrt{\lambda_\ell}} \sum_{j=1}^{I} \frac{f_{ij}}{f_{+j}} F_{\ell(i)},$$

Représentation jointe lignes et colonnes

Remarques | **Visualisation**

On peut donc représenter lignes et colonnes sur la même projection.

```
fviz_ca(penguins.CA)
```




```
penguin.cont |> rownames_to_column(var = 'island') |>
```

Interprétation jointe lignes et colonnes

Puisque l'origine du repère est confondue avec le barycentre des nuages.

- Si un profil ligne a une coordonnée positive sur un axe, il s'associe
  - plus que dans le modèle d'indépendance aux modalités j ayant une coordonnées positive
  - moins que dans le modèle d'indépendance aux modalités j ayant une coordonnées négative

Inerties associés aux axes

En AFC, l'inertie a un sens particulier.

En effet, si on considère la projection de N_I sur l'axe ℓ.

- Si on place chaque profil colonne $G_\ell(j)$ à l'exact barycentre, alors N_J est au centre du nuage N_I et donc N_I ne peut-être un nuage de barycentre de N_J.
- C'est la valeur λ_ℓ qui dilate les barycentres de $1/\sqrt{\lambda_\ell}$ et donc $\lambda_\ell \leq 1$.

La valeur propre 1 signifie que donc une association parfaite entre ligne et colonnes.

```
penguins.CA$eig[,1]
```

```
    dim 1     dim 2
0.6568035 0.1978211
```

Qualité de la représentation

Qualité de la représentation d'un profil ligne i

La qualité de la réprésentation de l'individu i sur l'axe ℓ est donné par

$$Qual_\ell(i) = \frac{\text{inertie de } i \text{ projeté sur } \ell}{\text{inertie de } i} = \frac{(OH_i^\ell)^2}{(Oi)^2}$$

inertie de i projeté sur ℓ

Contribution d'un profil i à l'inertie d'un axe

$$Cont_\ell(i) = \frac{\text{inertie de } i \text{ projeté sur } \ell}{\text{inertie de } N_I \text{ projeté sur } \ell} =$$

Etude des décès en France

Statistiques descriptives

Le fichier présente pour chaque tranche d'âge

- 65 lignes présentant le cumul de décès par cause en 1979 et 2006
- 65 lignes présentant le cumul de décès par cause en 2006
- 64 lignes présentant le cumul de décès par cause en 1979 (le SIDA n'est pas pris en compte)
- 28 lignes présentant le cumul de décès toutes causes confondues cause en 1979 à 2006.

```
deces_dta <- read.table("http://factominer.free.fr/livreV2/deces.c
                        check.names = TRUE, fileEncoding = "latin1
  rename(Cause = X) |>
  column_to_rownames(var = "Cause")
deces_dta <- deces_dta |> rownames_to_column("Cause") |>
  mutate(Periode = case_when(
    str_detect(Cause, pattern = "^[70][0-9]_") ~ str_extract(Cause
    str_detect(Cause, pattern = "^[12]+") ~ "Deces_annuel",
    str_detect(Cause, pattern = "^[0-9]+", negate = TRUE) ~ "Deces
    TRUE ~ NA_character_ # valeur par defaut
  ))
```

Test d'indépendance

Test sur toutes les données

```
deces_dta |> select(-Periode) |>
  column_to_rownames("Cause") |> chisq.test()
```

```
    Pearson's Chi-squared test

data:  column_to_rownames(select(deces_dta, -Periode), "Cause")
X-squared = 2695798, df = 2431, p-value < 2.2e-16
```

Test sur les données actives

```
deces_dta |>
  filter(Periode == "Deces_1979et2006") |>
  select(-Periode) |>
  column_to_rownames("Cause") |> chisq.test()
```

```
    Pearson's Chi-squared test

data:  column_to_rownames(select(filter(deces_dta, Periode == "Deces
X-squared = 1080254, df = 704, p-value < 2.2e-16
```

Analyse factorielle des correspondances (AFC)

Calcul et résumé de l'AFC

```
deces_dta <- deces_dta |>
  column_to_rownames("Cause") |>
  select(-Periode)
res.ca <- CA(deces_dta, row.sup = 66:nrow(deces_dta), ncp = 25,
             graph = FALSE)
summary(res.ca, nb.dec = 4)
```

```
Call:
CA(X = deces_dta, ncp = 25, row.sup = 66:nrow(deces_dta), graph = FALS

The chi square of independence between the two variables is equal to 1

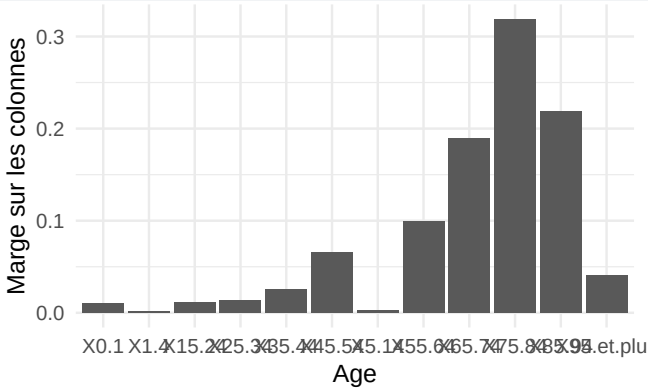
Eigenvalues
                Dim.1   Dim.2   Dim.3   Dim.4   Dim.5   Dim.6
Variance        0.5505  0.2570  0.1385  0.0338  0.0199  0.0143
% of var.      53.9002 25.1628 13.5653  3.3141  1.9439  1.4022
Cumulative % of var. 53.9002 79.0630 92.6283 95.9424 97.8863 99.2
                   Dim.7   Dim.8   Dim.9  Dim.10  Dim.11
```

AFC - Marges

Marges des colonnes et lignes

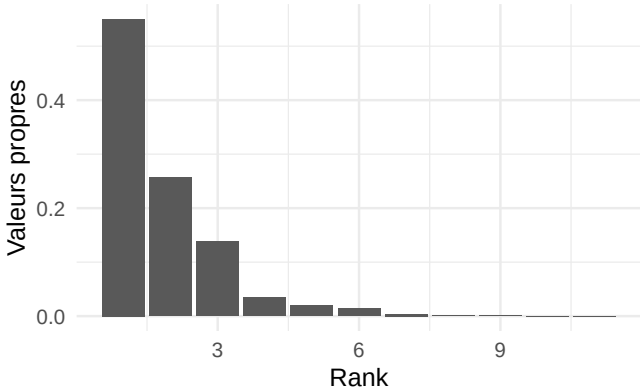
```
round(res.ca$call$marge.col, 3)
round(res.ca$call$marge.row[order(res.ca$call$marge.row)], 3)

tibble(marge_col = res.ca$call$marge.col, Age = colnames(deces_dta
  geom_bar(stat="identity") + ylab("Marge sur les colonnes")
```



AFC - Valeurs propres

```
tibble(eigen = res.ca$eig[,1], Rank = 1:length(res.ca$eig[,1]))
  geom_bar(stat="identity") + ylab("Valeurs propres")
```



Inertie par colonnes et lignes

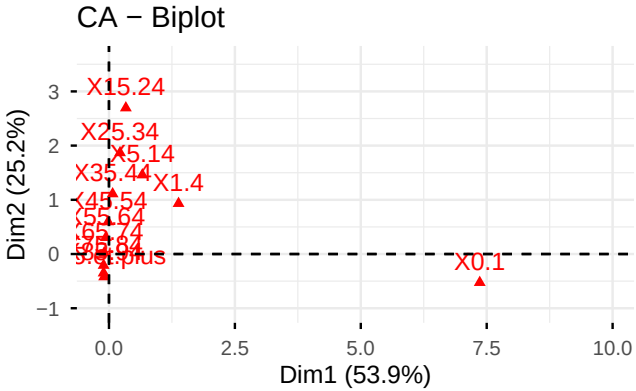
```
inertia.col <- tibble(Age= colnames(deces_dta),
                      poids = res.ca$call$marge.col,
                   inertie = res.ca$col$inertia,
                   percent.inertie = res.ca$col$inertia / sum(res.c
                   contrib_Dim1 = round(res.ca$col$contrib[,1],2),
                   contrib_Dim2 = round(res.ca$col$contrib[,2]),
                   contrib_Dim3 = round(res.ca$col$contrib[,3]))
inertia.col |>  arrange(-inertie) |> flextable()

inertia.row <- tibble(Cause= row.names(deces_dta[1:65,]),
                      poids = res.ca$call$marge.row,
                   inertie = res.ca$row$inertia,
                   percent.inertie = res.ca$row$inertia / sum(res.c
                   contrib_Dim1 = round(res.ca$row$contrib[,1],2),
                   contrib_Dim2 = round(res.ca$row$contrib[,2],2),
                   contrib_Dim3 = round(res.ca$row$contrib[,3],2))
inertia.row |>  arrange(-inertie)|> flextable()
```

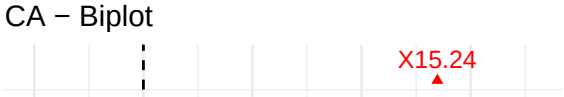
Age	poids	inertie	percent.inertie	contrib_Dim1	contrib_Dim2

Visualisation des résultats : axes 1 et 2

```
fviz_ca(res.ca, axes = 1:2, invisible = c("row", "row.sup"))
```

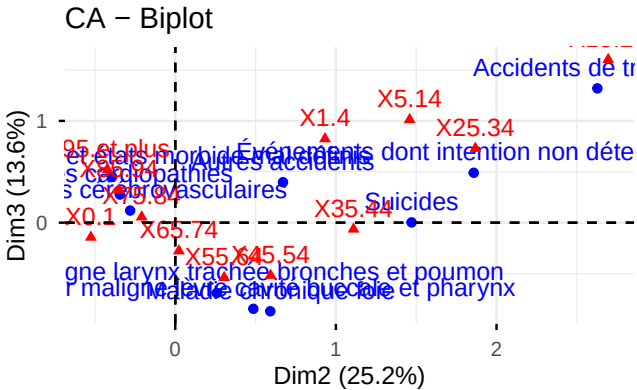



```
fviz_ca(res.ca, axes = 2:3, invisible = c("row", "row.sup"))
```



Visualisation des résultats : axes 2 et 3

```
fviz_ca(res.ca, axes = 2:3, invisible = c("row.sup"), select.row =
```



Distance et résumé des contributions

Distances entre colonnes

```
round(dist(res.ca$col$coord), 3)
```

```
          X0.1  X1.4 X5.14 X15.24 X25.34 X35.44 X45.54 X55.64 X65.74 X7
X1.4         6.818
X5.14        7.221 2.069
X15.24       7.965 3.656 2.008
X25.34       7.611 3.263 1.874  1.840
X35.44       7.495 3.241 2.118  2.694  1.250
X45.54       7.480 3.322 2.352  3.166  1.944  0.874
X55.64       7.483 3.354 2.428  3.329  2.171  1.175  0.412
X65.74     7.480 3.346 2.428  3.374  2.249  1.343  0.767  0.445
X75.84     7.480 3.342 2.445  3.410  2.312  1.496  1.073  0.827  0.422
X85.94     7.486 3.351 2.485  3.449  2.373  1.619  1.282  1.094  0.754
X95.et.plus 7.505 3.390 2.562  3.508  2.463  1.766  1.491  1.355  1.098
            X85.94
X1.4
X5.14
X15.24
```

Résumé des contributions (axes 2 à 5)

```
round(data.frame(CTR = res.ca$col$contrib[,2:5],
                 CO2 = res.ca$col$cos2[,2:5]), 3)
```

	CTR.Dim.2	CTR.Dim.3	CTR.Dim.4	CTR.Dim.5	CO2.Dim.2	CO2.Dim.3
X0.1	1.060	0.146	0.015	0.599	0.005	0.000
X1.4	0.711	1.031	2.089	58.057	0.083	0.065
X5.14	2.659	2.375	4.075	15.458	0.401	0.193
X15.24	33.216	21.793	13.518	0.920	0.684	0.242
X25.34	18.946	5.357	4.207	6.381	0.771	0.118
X35.44	12.049	0.074	19.113	1.596	0.759	0.003
X45.54	9.017	12.762	11.460	2.453	0.498	0.380
X55.64	3.585	20.883	0.002	2.923	0.227	0.713
X65.74	0.038	10.562	11.896	0.471	0.005	0.690
X75.84	5.439	0.719	9.790	5.097	0.573	0.041
X85.94	10.447	16.309	6.272	0.298	0.492	0.414
X95.et.plus	2.832	7.988	17.564	5.747	0.253	0.385

	CO2.Dim.4	CO2.Dim.5
X0.1	0.000	0.000
X1.4	0.032	0.523

Résultats supplémentaires

Suppression et ajustement des éléments supplémentaires

```
#|

row_sup =  res.ca$row.sup$coord[, 1:3] |> as.data.frame() |> rowna

row_annee <- row_sup |> filter(str_detect(rowname, pattern = "^[12

annees = deces_dta |> rownames_to_column("Cause") |> filter(str_de

# fviz_ca(res.ca, invisible = c( "col"), select.row=  list(contrib
# geom_point(data = row_annee, aes(x=`Dim 2`, y = `Dim 3`)) +
# geom_text(data = row_annee, aes(x=`Dim 2`, y = `Dim 3`, label =

fviz_ca(res.ca, invisible = c( "col"), axes = 2:3) +
geom_point(data = row_annee, aes(x=`Dim 2`, y = `Dim 3`)) +
geom_text(data = row_annee, aes(x=`Dim 2`, y = `Dim 3`, label = ro
```



Bilan

Ce que vous pensez devoir retenir

pour des données qualitatives, avec seulement deux variables qualitatives

Le tableau de contingence est à la base de la méthode

On commence par un test du chi2 qui teste l'independance

Les notions de profils lignes et profils colonnes

On fait deux ACPS : * une ACP sur les profils lignes affcetés du poids de sa marge avec la métrique 1/ marge de la colonne * une ACP sur les profils colonnes affcetés du poids de leur marge avec la métrique 1/ marge de la ligne

la métrique est choisi pour que l'inertie totale soit le coefficient phi du test de chi2 (chi2/n)

C'est une mesure d'écart à l'independance

Une des forces de l'ACP est la représentation jointe de slignes et des colonnes grâce aux relations barycenytriques

les profils lignes ayant de svaleur positives sur un axe sont associés préférentiellement aux colonnes ayant des valeurs, tandis qu'ils s'associent moins qu'attendu avec les colonnes qui ont des valeurs négatives