Analyse Factorielle Multiple

Une ACP avec une métrique particulière

Marie-Pierre Etienne

https://marieetienne.github.io/MAF/

2026-11-10

Introduction

Quelques exemples

On a mesuré les caractéristiques physico chimiques sur 30 sites différents le long de la rivière Doubs.

Les 4 premières lignes (parmi 30) du jeu de données doubs.env

```
# A tibble: 30 x 11
   das  alt  pen  deb   pH  dur  pho  nit  amn  oxy  deb
 <dbl> <int> <dbl> <dbl> <dbl> <int> <dbl> <dbl> <dbl> <dbl> <dbl>
1  0.3  934  48   0.84  7.9   45  0.01  0.2   0   12.2  2.7
2  2.2  932   3    1     8     40  0.02  0.2   0   10.3  1.9
3 10.2  914   3.7  1.8   8.3   52  0.05  0.22  0.05 10.5  3.5
4 18.5  854   3.2  2.53  8     72  0.1   0.21  0   11    1.3
# i 26 more rows
```

On mesure des caractéristiques physiques, des caractéristiques chimiques, des caractéristiques écologiques.

- das : distance à la source (km),
- alt : altitude (m)
- pen : la pente (définie pour 100 m)
- deb : le débit ($m^3.s^{-1}$)
- pH : le pH de l'eau
- dur : la concentration en calcium ($mg.L^{-1}$),
- pho : concentration en phosphate ($mg.L^{-1}$),
- nit : concentration en nitrate ($mg.L^{-1}$),
- amn : concentration en

Quelques exemples

On s'intéresse aux notes des 30 élèves d'une classe. Le tableau de note complet contient

- 8 notes de mathématiques
- 4 notes d'anglais
- 3 notes d'histoire géographie
- 3 notes de français
- 1 note de dessin

On aimerait visualiser les notes à l'aide d'une méthode factorielle, notamment pour savoir si ce sont les mêmes élèves qui rencontrent des difficultés dans les différentes matières.

- On normalise les données car les gammes de variation des notes dans les différentes matières sont assez différentes
- Que se passe-t-il si on fait une ACP normée ?

Les mathématiques ont 8 fois plus de poids dans la détermination des axes

Quelques exemples

Exemple tiré des cours de F. Husson

10 vins blancs du Val de Loire : 5 Vouvray - 5 Sauvignon ▪ descripteurs sensoriels : acidité, amertume, odeur agrume, etc.

```
#|
vins <- read.table("https://husson.github.io/MOOC_AnaDo/AnaDo_JeuDo
      header=TRUE, sep=";",dec=".", row.names=1, check.names=FALSE,
head(vins, n= 4)
```

```
                cepage Int.av.agitation Int.ap.agitation Expression
S Michaud     Sauvignon          7.750          8.000   7.142857
S Renaudie    Sauvignon          7.125          7.625   7.000000
S Trotignon   Sauvignon          7.125          7.375   7.142857
S Buisse Domaine Sauvignon       5.500          6.250   5.428571
                0.fruit 0.passion 0.agrume 0.fruit.sec 0.vanille 0.boise
S Michaud      4.250000  2.428571 5.714286   5.000000  0.6666667 0.5000000
S Renaudie     4.428571  3.142857 5.250000   6.666667  0.5000000 0.5000000
```

10 vins blancs du Val de Loire : 5 Vouvray - 5 Sauvignon

- descripteurs sensoriels : acidité, amertume, odeur agrume, etc.
- description sensorielle de 3 jurys
- notes hédoniques de 7 consommateurs [appréciation globale]{. vert}

Formalisation du problème

$$X = \begin{pmatrix} X_1^1 & X_1^2 & X_1^3 & X_1^4 & X_1^5 & X_1^6 & X_1^7 \\ \vdots & \vdots & \vdots & \vdots & \vdots & \vdots & \vdots \\ X_n^1 & X_n^2 & X_n^3 & X_n^4 & X_n^5 & X_n^6 & X_n^7 \end{pmatrix} = \begin{pmatrix} X^1 & X^2 & X^3 \end{pmatrix}$$

On souhaite mettre en évidence

- Les relations entre les groupes de variables
- Equilibrer les contribution de chaque groupe de variables

Première idée

- Rééquilibrer les variables entre groupes en attribuant à chaque variable k du groupe i un poids $1/n_k$, où n_k est le nombre de variables dans le groupe k.

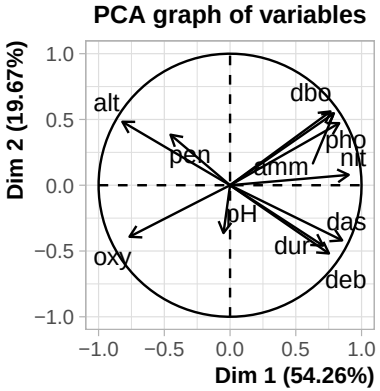


Figure: ACP normée

Poids des groupes de variables (variance préservée)

	Physique	Chimique	Ecologic
1	2.95876411	2.85278619	1.781
2	0.75987927	1.03668447	0.151
3	0.11984792	0.71729362	0.000
4	0.02817537	0.20119043	0.000
5	0.00000000	0.02537862	0.000

Contribution des variables aux différents axes

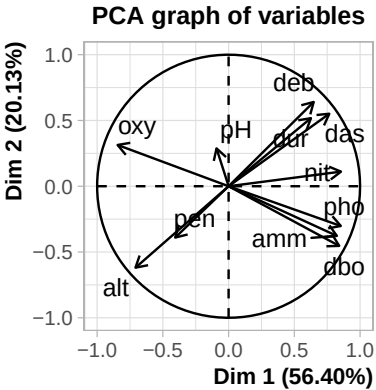
	Dim.1_acp	Dim.2_acp	Dim.
das	12.18484089	8.1162594	8.9
alt	11.24282498	10.7604372	7.(
pen	3.43552777	6.8155752	2.5
deb	9.47810542	12.4294474	6.4

Illustration

- Rééquilibrer les variables entre groupes en attribuant à chaque variable k du groupe i un poids $1/n_k$, où n_k est le nombre de variables dans le groupe k.

Problème

- les deux variables écologiques sont presque parfaitement corrélées, l'information qu'elles portent se résume très bien avec un seul axe. Ainsi cet axe porte presque la même information que l'ensemble des variables, elles ont donc beaucoup de poids dans la création des axes finaux.
- Les variables chimiques (pH, dureté, phosphate, nitrite et



	Physique	Chimique	Ecologique
1	0.739691027	0.570557238	0.890841
2	0.189969817	0.207336895	0.075824
3	0.029961980	0.143458724	0.00000

L'AFM en pratique

Pour chaque groupe de variable k,

- On calcule la 1ère valeur propre λ_{k1} du groupe de variable k, (chaque variable ayant été normée)
- On réalise l'ACP globale sur le tableau pondéré :

$$X = \begin{pmatrix} \frac{X_1^1}{\sqrt{\lambda_{11}}} & \frac{X_1^2}{\sqrt{\lambda_{11}}} & \frac{X_1^3}{\sqrt{\lambda_{11}}} & \frac{X_1^4}{\sqrt{\lambda_{21}}} & \frac{X_1^5}{\sqrt{\lambda_{21}}} & \frac{X_1^6}{\sqrt{\lambda_{31}}} & \frac{X_1^7}{\sqrt{\lambda_{31}}} \\ \vdots & \vdots & \vdots & \vdots & \vdots & \vdots & \vdots \\ \frac{X_n^1}{\sqrt{\lambda_{11}}} & \sqrt{\frac{X_n^2}{\lambda_{11}}} & \frac{X_n^3}{\lambda_{11}} & \frac{X_n^4}{\lambda_{21}} & \frac{X_n^5}{\sqrt{\lambda_{21}}} & \sqrt{\frac{X_n^6}{\lambda_{31}}} & \frac{X_n^7}{\lambda_{31}} \end{pmatrix}$$
$$= \begin{pmatrix} \frac{X^1}{\sqrt{\lambda_{11}}} & \frac{X^2}{\sqrt{\lambda_{21}}} & \frac{X^3}{\sqrt{\lambda_{31}}} \end{pmatrix}$$

On a ainsi la pondération

	Methode	Physique	Chimique	Ecologique
1	ACP	3.0	2.9	1.8
2	ACP	0.8	1.0	0.2
3	ACP	0.1	0.7	0.0
4	ACP	0.0	0.2	0.0

L'AFM : une ACP Particulière

Finalement dans une AFM, on étudie

- le nuage de points X,
- Les points sont potentiellement pondérés avec la matrice de poids $W \in \mathbb{R}^{n \times n}$,
- on utilise la mérique

$$M = Diag\left(\frac{1}{s_1^2 \lambda_{c_1}}, \dots, \frac{1}{s_p^2 \lambda_{c_p}}\right)$$

où Diag désigne la matrice diagonale, le terme i est donné par $\frac{1}{s_i^2 \lambda_{c_i}}$, s_i est l'écart type de la variable i et λ_{c_i} est la première valeur propre de la classe à laquelle appartient la variable i.

On a notre tryptique

$$(X, W, M)$$

Analyse des groupes de variables

L'analyse des individus et des variables se fait comment en ACP.

Qualité de la représentation d'un groupe de variables j.
en ACP, on maximise

$$\frac{1}{n}\|Xu_1\|_M^2 = \frac{1}{n}\sum_{j=1}^{p}({u_1}^\top X^j)^2\, m_j$$

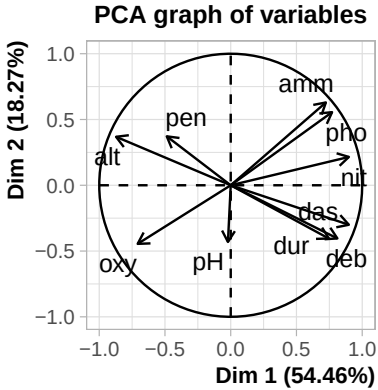
Réécriture avec les groupes

$$\frac{1}{n}\|Xu_1\|_M^2 = \frac{1}{n}\sum_{j=1}^{p}({u_1}^\top X^j)^2\, m_j = \sum_{\ell=1}^{n_g}\frac{1}{n}\sum_{j\in K_\ell}({u_1}^\top X^j)^2\, m_j$$

$\mathcal{L}_g(K_\ell, u_1) = \frac{1}{n}\sum_{j\in K_\ell}({u_1}^\top X^j)^2\, m_j$ est l'inertie projetée de toutes les variables de K_j sur u_1
Ainsi $\mathcal{L}_g(K_\ell, u_1)$ est le mesure du lien entre le groupe ℓ et la première dimension.

En pratique

```
doubs.env_dbo <- doubs.env |> select(-dbo)
doubs.env_dbo_pca <- PCA(doubs.env_dbo, graph = FALSE)
plot(doubs.env_dbo_pca, choix = "var")
```




```
doubs_mfa <- MFA(doubs.env_dbo,
    group = c(4, 5, 1), # un vecteur qui spécifie le nombre de var
    type = rep("s", 3), # pour indiquer que ce sont des variables
```

Bilan

Ce que vous pensez devoir retenir

On *choisit* de faire une AFM si on veut mettre l'accent sur les liens entre les groupes de variables

- Pour ce faire, on veut que chaque groupe contribue de la même manière à construire des premmiers axes principaux
- Pour normaliser l'importance de chaque groupe, on calcule la première valeur propre de chaque groupe et on normalise les données par la racine de cette vp, ou de manière équivalente on prend une métrique $M£ dans maquelle le terme M_{ii} contient la première valeur propre du groupe de variables auquel appartient i.

La méthode est proche de l'ACP, c'est une ACP avec une métrique particulière.

On va inetrpéter les relations entre les groupes de variables.