Une mesure de la quantité d'information

Marie-Pierre Etienne

https://marieetienne.github.io/MAF/

2026-11-04

Inertie par rapport à un point

L'inertie d'un nuage de points

Définition

$$I = \frac{1}{n} \sum_{i=1}^{n} d(x_i, g)^2,$$

où g désigne le point qui résume le mieux l'ensemble des données.

C'est la quantité d'information contenue dans le nuage de points

ou

C'est la quantité d'information perdue lorsque l'on résume l'ensemble du nuages de points par le point g

L'inertie d'un nuage de points

Il faut donc une

- une notion de distance
- un point résumé

Quelle distance choisir et que représente g ?

- On peut choisir la distance euclidienne

$$d(x_i, g)^2 = \sum_{j=1}^{p} (x_i^j - g^j)^2.$$

L'inertie d'un nuage de points

Quelle distance choisir et que représente g ?

- On peut choisir la distance euclidienne

$$d(x_i, g)^2 = \sum_{j=1}^{p} (x_i^j - g^j)^2.$$

- $g = (\bar{x^1}, \dots, \bar{x^p})$ est un choix naturel et la distance euclidienne

D'autres choix sont possibles pour la distance, dont certaines adaptées aux variables qualitatives. Il faudra réfléchir à qui est g dans le cas de données qualitatives

le choix de la distance est le des différences entre ACP, AFC, ACM etc ... A venir donc ...

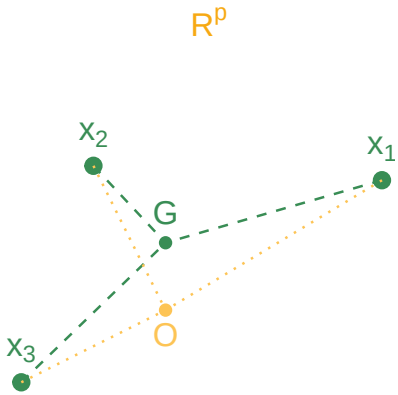
L'inertie par rapport d'un nuage par rapport à un point quelconque

Definition

L'inertie *par rapport à un point* $a \in \mathbb{R}^p$ est définie par

$$I_a = \frac{1}{n}\sum_{i=1}^{n} d(x_i - a)^2 = \frac{1}{n}\sum_{i=1}^{n}\sum_{k=1}^{p}(x_i^k - a^k)^2$$

L'inertie par rapport d'un nuage par rapport à un point quelconque



L'inertie par rapport d'un nuage par rapport à un point quelconque

L'inertie par rapport à un point quantifie l'information perdue lorsque le jeu de données est résumé par ce point.

Quel est selon vous le point a qui minimise l'inertie ?

$$\arg\min_a I_a = ??$$

L'inertie par rapport d'un nuage par rapport à un point quelconque

BINGO !!!

Il s'agit du point $g = x_\bullet = (x_\bullet^1, \dots, x_\bullet^p)^\top$, avec $x_\bullet^k = \frac{1}{n} \sum_{i=1}^n x_i^k$, la valeur moyenne de la variable k sur l'ensemble des individus.

Si les variables étaient centrées, alors $g = O$ l'origine sur repère.

L'inertie par rapport d'un nuage par rapport à un point quelconque

$$\forall a \in \mathbb{R}^p,\ I_a = I_g + \|a - g\|^2.$$

(preuve dans les notes de cours)

L'inertie du nuage de points

Rappel Definition

L'inertie *du nuage de points* représentés par X est l'inertie par rapport à son barycentre

$$I = \frac{1}{n} \sum_{i=1}^{n} \|x_i - g\|^2$$

Conséquence

Le meilleur résumé du nuage de points à un unique point est le barycentre du nuage de points, c'est à dire la moyenne sur chacune des dimensions.

La quantité d'information perdue lors de ce résumé est I

Des extensions I

Poids des individus

Si l'on souhaite accorder plus de poids à certains individus (par exemple poids du pays en fonction de sa population), on peut considérer le nuage de points **pesants** (x_i, ω_i) où ω_i est le poids associé à l'individu i, avec $\sum_i \omega_i = 1$
Le barycentre est bien défini g comme le barycentre des points pondérés et l'inertie par rapport à un point a quelconque est donné par

$$I = \frac{1}{n} \sum_{i=1}^{n} \omega_i \|x_i - a\|^2$$

Des extensions II

Choix de la distance

On a évoqué la distance Euclidienne mais toute autre distance est possible. Chaque choix de distance correspond à une méthode d'analyse factorielle différente.

- euclidienne : ACP
- euclidienne normalisée : ACP normée ou AFM selon le type de normalisation
- distance du χ^2 : AFC ou ACM

Cours présenté sans les poids mais tout se généralise.

Lien entre inertie et variance

Dans le cas de la distance euclidienne, on met en évidence un lien fort entre inertie et variance dans les données.

En effet :

$$I = \frac{1}{n}\sum_{i=1}^{n}\left(\sum_{k=1}^{p}(x_i^k - x_\bullet^k)^2\right) = \sum_{k=1}^{p}\left(\frac{1}{n}\sum_{i=1}^{n}(x_i^k - x_\bullet^k)^2\right) = \sum_{k=1}^{p} Var(x^k)$$

Si les variables sont réduites, i.e de norme 1 :

$$I = p$$

Où l'on commence à introduire l'algèbre linéaire

Formellement, il nous faut

- une matrice X (dimension $n \times p$),
- une distance, i.e une métrique (dimension $p \times p$)
- Optionnellement une matrice de poids D

Définition

Une métrique M est une matrice de $\mathbb{R}^{p \times p}$ symétrique, définie et positive. Elle permet de définir une distance entre les observations.

Si $x_1 \in \mathbb{R}^p$ et $x_2 \in \mathbb{R}^p$, la distance entre x_1 et x_2 pour la métrique M est

$$d_M(x_1, x_2) = \|x_1 - x_2\|_M$$

où

$$\|x_1 - x_2\|_M^2 = (x_1 - x_2)^\top M (x_1 - x_2).$$

Que vaut M dans le cas euclidien ?

$M = I_p$, en effet si $x_1 \in \mathbb{R}^p$ et $x_2 \in \mathbb{R}^p$,

alors

$$x_1 - x_2 = \begin{pmatrix} x_1^1 - x_2^1 \\ \vdots \\ x_1^p - x_2^p \end{pmatrix},$$

donc

$$(x_1 - x_2)^\top (x_1 - x_2) = \sum_{j=1}^{p} (x_1^j - x_2^j)^2.$$

On définit la matrice des données centrées

$$\tilde{X} = X - 1_n g = \begin{pmatrix} x_1^1 - g^1 & x_1^2 - g^2 & \dots & x_1^p - g^p \\ \vdots & & & \vdots \\ x_n^1 - g^1 & x_n^2 - g^2 & \dots & x_n^p - g^p \end{pmatrix}$$

Alors

$$I = \frac{1}{n} tr(\tilde{X}^\top \tilde{X}).$$

Et dans toute la suite

On va supposer que les données sont centrées (quitte à effectuer le centrage) et donc

$$X = \tilde{X}$$

et $g = O$.

Inertie par rapport à un sous espace affine

L'inertie par rapport à un axe passant par g

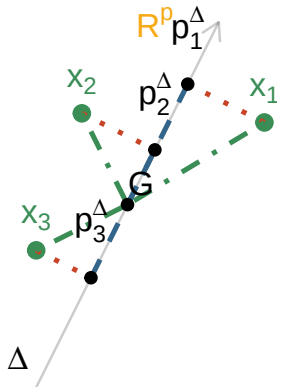
Definition

L'inertie *par rapport à l'axe* Δ passant par g est définie par

$$I_\Delta = \frac{1}{n}\sum_{i=1}^{n} d(x_i - p_i{}^{\Delta})^2$$ où $p_i{}^{\Delta}$ est le projeté orthogonal de x_i sur Δ.

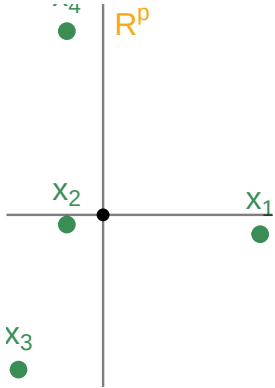
L'inertie par rapport à un axe passant par g

L'inertie par rapport à l'axe Δ quantifie l'information perdue lorsque l'on résume le nuage de points à son projeté sur Δ. On perd toute l'information "orthogonale".



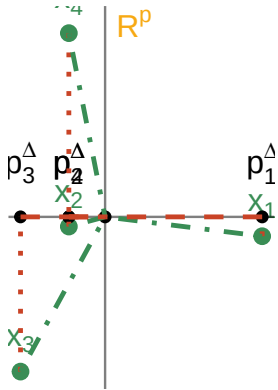
L'inertie par rapport à un axe passant par g

Quelle est l'inertie par rapport à l'axe des abscisses ?



L'inertie par rapport à un axe passant par g

L'inertie par rapport à l'axe Δ quantifie l'information perdue lorsque l'on résume le nuage de points à son projeté sur Δ. On perd toute l'information "orthogonale".



Projeter en perdant un minimum d'information

Identifier Δ tel que I_Δ soit minimale

Ce qui revient à identifier l'axe Δ qui assure que la projection sur Δ déforme le moins possible le nuage de points.

Dans le cadre de l'ACP, on veut construire un ensemble d'axes orthogonaux (une nouvelle base de $\mathbb{R}^p$), de façon à ce que

- la projection sur le premier axe, soit le meilleur résumé du nuage de points en une dimension,
- le deuxième axe est orthogonal au premier et représente "le deuxième meilleur choix" ... dans un sens que l'on va définir,
- le troisième ...

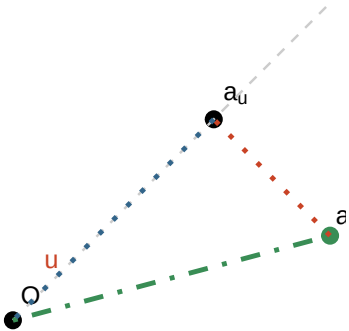
Où l'algèbre linéaire revient I

Rappel projection orthogonale

- **Produit scalaire** : Soient deux éléments x et y de $\mathbb{R}^p$, le produit scalaire est noté $\langle x, y \rangle$ et $\langle x, y \rangle = \sum_{i=1}^{p} x_i y_i = x^\top y$.
- **Orthogonalité** : on dit que x et y sont orthogonaux si $\langle x, y \rangle = x^\top y = 0$.
- **Projection orthogonale** : le projeté de a sur la droite Δ de vecteur directeur unitaire u est

$$a_u = \langle a, u \rangle u = (a^\top u)\, u.$$

Projection orthogonale d'un point A su



Remarque

Que signifie projeter sur l'axe des abscisses ? sur l'axe des ordonnées ?

- Il y a un lien fort entre coordonnées dans un système d'axes et projection.

Où l'algèbre linéaire revient III

- Si on sait projeter sur un autre système orthogonal, on a les coordonnées.

Où l'algèbre linéaire reste encore

- **Espace orthogonal** : Soit E un sous-espace vectoriel de $\mathbb{R}^p$. On définit $E^\perp = \{x \in \mathbb{R}^p : \forall y \in E,\ x \perp y\}$.

Exemple Solution

Dans $\mathbb{R}^2$, on considère le sous espace vectoriel E, tel que

$$E = \left\{ x = \begin{pmatrix} x_1 & x_2 \end{pmatrix}^\top \in \mathbb{R}^2 : x_1 = x_2 \right\}$$

E est la droite d'équation $y = x$. Qui est $E^\perp$?

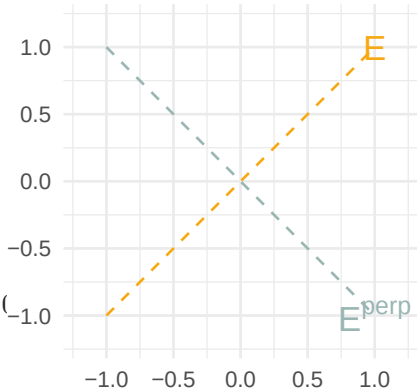
Où l'algèbre linéaire reste encore

Exemple **Solution**

Soit $x \in E$, et $y \in E^\perp$, alors

$$
\begin{aligned}
0 &= x^\top y \\
&= x_1 y_1 + x_2 y_2 \\
&= x_1(y_1 + y_2) \quad (x \in E \Rightarrow x_1 = x_2)
\end{aligned}
$$

$$E^\perp = \Big\{ y = \begin{pmatrix} y_1 & y_2 \end{pmatrix}^\top \in \mathbb{R}^2 : y_1 + y_2 = 0$$



L'inertie par rapport à un sous espace affine

Definition

L'inertie *par rapport à un sous espace affine* E passant par l'origine est définie par

$$I_E = \frac{1}{n}\sum_{i=1}^{n} \|x_i - {p_i}^E\|^2, \quad \text{où} \quad {p_i}^E = \arg\min_{y \in E} d(y, x_i).$$

C'est l'inertie perdue lorsque l'on résume le nuage de points à sa projection sur le sous espace E.

Décomposition de l'inertie I

Lemme

Soit E un sous espace vectoriel de $\mathbb{R}^p$, alors

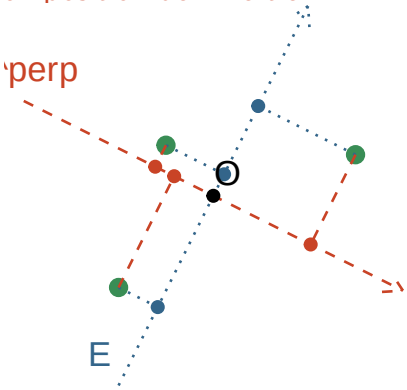
$$I = I_E + I_{E^\perp}.$$

Preuve : Un dessin vaut mieux qu'un long discours et Pythagore est votre ami !

$$\|x_i\|^2 = \|x_i - x_i^E\|^2 + \|x_i^E\|^2 = \|x_i - x_i^E\|^2 + \|x_i - x_i^{E^\perp}\|^2.$$

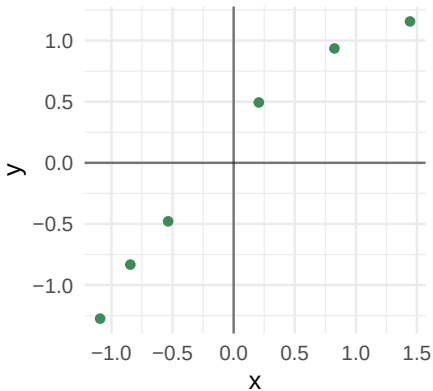
En sommant : $I = I_E + I_{E^\perp}$.

Décomposition de l'inertie II



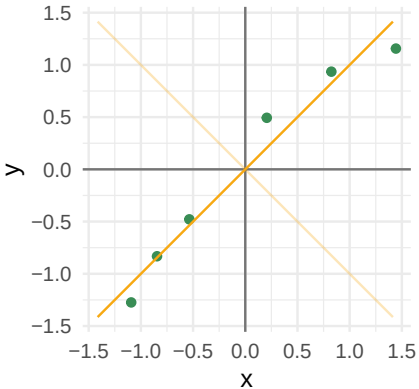
L'objectif en image

L'objectif en image



L'objectif en image

Au début | **Un nouveau repère** | Info perdue | But final



L'objectif en image

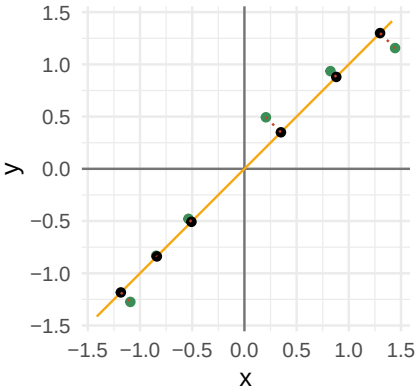


Figure: *Sur l'axe 1*

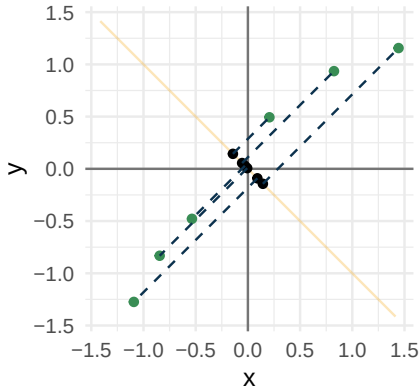
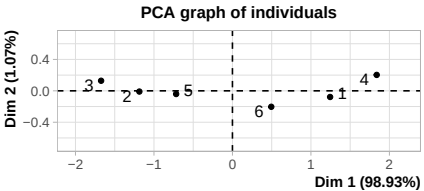
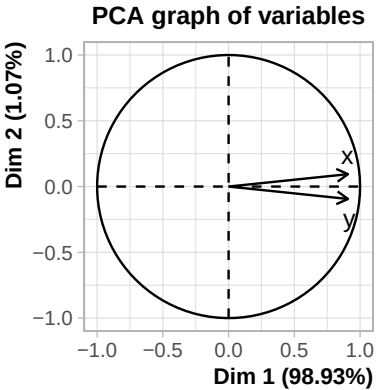


Figure: *Sur l'axe 2*

L'objectif en image





Principe de toutes les décompositions à venir

1. Identifier le vecteur u_1 de $\mathbb{R}^p$, tel que I_{E_1} soit minimale avec $E_1 = \{\lambda u_1, \lambda \in \mathbb{R}\}$.
2. Dans $E_1^{\perp}$, identifier le vecteur u_2 de $\mathbb{R}^p$, tel que I_{E_2} soit minimale avec $E_2 = \{\lambda u_2, \lambda \in \mathbb{R}\}$.
3. Dans $(E_1 \oplus E_2)^{\perp}$, identifier le vecteur u_3 de $\mathbb{R}^p$, tel que ....

Principe de toutes les décompositions à venir

1. Identifier le vecteur u_1 de $\mathbb{R}^p$, tel que I_{E_1} soit minimale avec $E_1 = \{\lambda u_1, \lambda \in \mathbb{R}\}$.
2. Dans $E_1^{\perp}$, identifier le vecteur u_2 de $\mathbb{R}^p$, tel que I_{E_2} soit minimale avec $E_2 = \{\lambda u_2, \lambda \in \mathbb{R}\}$.
3. Dans $(E_1 \oplus E_2)^{\perp}$, identifier le vecteur u_3 de $\mathbb{R}^p$, tel que ....

Finalement on aura la décomposition

$$I = I_{E_1} + I_{E_2} + ... + I_{E_p}, \quad \text{avec } I_{E_1} \leq I_{E_2} \leq ... \leq I_{E_p}$$

En quoi est ce utile ?

- L'essentiel de l'information est portée par les premiers axes (puisque ce sont les axes sur lesquels on perd le moins d'information lorsqu'on projette)
  - facilité de visualisation
  - compression de l'information
- Ce qui est plus complexe
  - donner un sens aux nouveaux axes

Conclusion

Bilan de ce cours

- Mise en place de tous les outils de base
- L'inertie = de l'information
- on veut le plus d'information avec le moins de "variables possibles"
- on va utiliser de l'algèbre linéaire
- Il nous reste à comprendre comment trouver ce bon système d'axe